

1. RESUMEN EJECUTIVO

El presente documento describe el analisis predictivo de la produccion de azucar en Mexico utilizando datos abiertos del sistema INFOCANA. El proyecto aplica tecnicas de ETL (Extract, Transform, Load), regresion lineal y series de tiempo para predecir la produccion de azucar basada en variables como la cana molida y la superficie cosechada.

El dashboard desarrollado permite visualizar datos historicos, comparar ingenios y zafras, y generar predicciones para la proxima zafra.

2. FUENTE DE DATOS

2.1 Descripcion del Dataset

Los datos fueron obtenidos de INFOCANA (datos.gob.mx), conteniendo informacion de produccion azucarera de Mexico desde la zafra 2012-2013 hasta 2025-2026.

Estadisticas del Dataset:

- Total de registros: 14,667
- Numero de ingenios: 87
- Numero de zafras: 13
- Columnas disponibles: 65
- Semanas por zafra: 1 a 14

2.2 Variables Principales

Variable	Descripcion	Unidad
azucar_producida_total	Toneladas de azucar total	toneladas
cana_molida_bruta	Cana molida total	toneladas
cana_molida_neta	Cana molida neta	toneladas
superficie_cosechada	Superficie cosechada	hectareas
rendimiento_campo	Rendimiento por hectarea	ton/ha
rendimiento_fabrica	Eficiencia en fabrica	%

3. PROCESO ETL

El proceso de ETL (Extract, Transform, Load) se implemento para preparar los datos crudos para el analisis:

EXTRACCION:

- Se leyeron archivos CSV del directorio 'data/'
- Archivos con formato: infocana_XX_XX_resumen*.csv

TRANSFORMACION:

- Normalizacion de nombres de ingenios
- Estandarizacion de formatos de numeros
- Generacion de variable 'ingenio_normalizado'
- Imputacion de azucar_producida_total con azucar_total

CARGA:

- Combinacion de todos los archivos en un solo DataFrame
- Filtrado y limpieza de datos inconsistentes

4. MODELO DE REGRESION LINEAL

Se implemento un modelo de regresion lineal simple para predecir la produccion total de azucar (Y) basandose en la cantidad de cana molida neta (X).

Parametros del Modelo:

- Algoritmo: LinearRegression de scikit-learn
- Division de datos: 80% entrenamiento, 20% prueba
- Metricas evaluadas: R2 Score, RMSE, MAE

Resultados del Modelo (ejemplo con ingenio 'el refugio', zafra 2019-2020):

Metrica	Valor
R2 Score	0.9969
RMSE	641.31 ton
MAE	560.11 ton
Pendiente (coef)	0.1102
Intercepto	-1,711.13

5. MODELO DE SERIES DE TIEMPO

Se implemento un modelo de series de tiempo para forecasting.

Metodologia:

- Modelo: ExponentialSmoothing con tendencia aditiva y estacionalidad
- Periodo estacional: 4 (semanas)
- El modelo captura patrones estacionales en la produccion

Interpretacion:

- La grafica muestra los datos historicos de produccion
- La linea punteada indica el inicio de las predicciones
- Las predicciones se generan para 1 a 24 semanas futuras

6. DASHBOARD SHINY

Se desarrollo un dashboard interactivo utilizando Shiny para Python.

FUNCIONALIDADES:

- Seleccion de ingenio y zafra para analisis detallado
- Visualizacion de tendencias de produccion
- Mapas de calor (heatmaps) para comparacion
- Analisis de regresion lineal con metricas
- Pronosticos de series de tiempo
- Tablas de datos con informacion detallada

TECNOLOGIAS UTILIZADAS:

- Python 3.11+
- Shiny for Python
- Plotly para visualizaciones
- Pandas para manipulacion de datos
- scikit-learn para machine learning
- statsmodels para series de tiempo

7. RESULTADOS PRINCIPALES

7.1 Top 10 Ingenios por Produccion

Ingenio	Produccion Total (ton)
Tres Valles	44,564,753
Atencingo	35,307,777
Panuco	30,997,690
La Fe	30,951,907
San Miguel Del Naranjo	30,938,550
El Higo	28,682,184
San Rafael De Pucte	27,457,914
Adolfo Lopez Mateos	27,330,539
San Cristobal	26,872,484
Huixtla	25,627,901

7.2 Produccion por Zafra

Zafra	Produccion Total (ton)
2012-2013	104,983,857
2014-2015	85,410,542
2015-2016	82,887,705
2016-2017	74,249,808
2017-2018	82,152,577
2018-2019	77,587,954
2019-2020	58,838,524
2020-2021	72,425,531
2021-2022	84,059,573
2022-2023	65,041,867
2023-2024	58,561,283
2024-2025	56,375,650
2025-2026	1,756,486

8. CONCLUSIONES

1. El modelo de regresion lineal muestra una fuerte correlacion entre la cantidad de cana molida y la produccion de azucar.
2. Los modelos de series de tiempo capturan efectivamente los patrones estacionales de la produccion azucarera.
3. El dashboard proporciona una herramienta accesible para explorar los datos y generar insights.
4. Los datos de INFOCANA son una fuente valiosa para el analisis de la industria azucarera mexicana.
5. Se recomienda actualizar periodicamente los datos para mantener la relevancia de las predicciones.

9. RECOMENDACIONES

1. Implementar un pipeline automatizado para la actualizacion de datos.
2. Considerar modelos de machine learning mas avanzados (Random Forest, XGBoost).
3. Agregar validacion cruzada para mejorar la robustez de las metricas.
4. Expandir el dashboard con mas visualizaciones y comparativas.
5. Desplegar el dashboard en GitHub Pages para acceso publico.
6. Generar reportes automaticos periodicos con los pronosticos.

10. REFERENCIAS

- INFOCANA: Sistema de Informacion de la Cana de Azucar
<https://datos.gob.mx/busca/dataset?tags=infocana>
- Documentacion Shiny for Python:
<https://shiny.posit.co/>
- scikit-learn:
<https://scikit-learn.org/>
- statsmodels:
<https://www.statsmodels.org/>
- Plotly Python:
<https://plotly.com/python/>